**1. MARCO TEÓRICO Y OBJETIVO....1**
**2. DESCRIPCIÓN Y PREPARACIÓN DE LOS DATOS....1**
**3. ANÁLISIS PRELIMINAR....2**
3.1. Distribución de la variable dependiente:....2
3.2. Estadísticos descriptivos de las variables independientes:....3
3.3. Correlaciones con la variable dependiente y entre las predictoras....3
**4. ESPECIFICACIÓN DEL MODELO Y EVALUACIÓN....5**
4.1. Modelo inicial completo....5
4.2. Proceso de selección de variables:....6
4.3. Evaluación de interacciones:....7
**5. RESULTADOS, EVALUACIÓN DE SUPUESTOS Y MODELO FINAL....7**
**5.1 Evaluación de los supuestos del modelo....8**
5.2 Modelo definitivo....8
**6. DISCUSIÓN Y CONCLUSIONES....10**
**8. REFERENCIAS....11**
**9. ANEXO....12**

## 1. MARCO TEÓRICO Y OBJETIVO

El objetivo de este informe es construir un modelo que explique la probabilidad de que el Real Madrid marque dos o más goles en un partido de La Liga, en función de métricas del juego como los tiros, la posesión o los pases. Para ello, se utilizarán datos correspondientes a los partidos jugados por el Real Madrid en La Liga entre las temporadas 2017 y 2022.

Aunque existen múltiples trabajos centrados en predecir el resultado de partidos de fútbol o el número total de goles en ambos equipos (Constantinou et al., 2012; Hvattum & Arntzen, 2010), son menos frecuentes los estudios enfocados en estimar si un único equipo marcará una cierta cantidad de goles. Es por ello, que se modelará la probabilidad de que se marquen dos o más goles.

## 2. DESCRIPCIÓN Y PREPARACIÓN DE LOS DATOS

La base de datos empleada contiene información de todos los partidos que el Real Madrid ha disputado en La Liga entre las temporadas 2017 y 2022, con un total de 228 partidos. Cada fila representa un partido, y se incluyen un total de 14 variables independientes y 1 variable dependiente:

**Variable dependiente:** goles. Es una variable cuantitativa con valores positivos o iguales a cero que indica el número total de goles marcados por el Real Madrid en el partido. Para el presente análisis, se ha recodificado en una variable dicotómica llamada "***goles_dico"***, que toma los valores: 1 si el equipo marcó dos o más goles, 0 si el equipo marcó menos de dos goles. Esta dicotomización se justifica porque la media de goles por partido es 1,97. Además, la mediana es exactamente 2, lo que refuerza esta elección al representar un valor central más robusto frente a posibles asimetrías o extremos en la distribución.

**Variables independientes o predictoras:** hay 12 variables cuantitativas y dos categóricas:

- La variable ***venue*** es una variable dicotómica que indica el lugar donde se ha disputado el partido, cuyas categorías son: *home* para partidos disputados como local y *away* para partidos disputados como visitante. Esta variable ha sido recodificada a numérica pasando a tener los valores: 0 para partidos jugados como local (home) y 1 para partidos jugados como visitante (away).
- El número de tarjetas rojas recibidas es la otra variable dicotómica que, aunque se podría tratar como cuantitativa discreta, en esta base únicamente toma dos valores (0 y 1).

Variables cuantitativas:

- Pos: porcentaje de posesión del balón (min=0, máx=100).
- Disparos: cantidad de disparos realizados a puerta (min=0, máx=17).
- Dist_disp: distancia media desde la que se realizaron los disparos (metros) (min=12, máx=26,10).
- Penal_afavor: número de penaltis a favor (min=0, máx=3). Aunque esta variable podría tratarse como categórica, realmente se trata de una variable cuantitativa discreta que en esta base de datos adopta un máximo de 3, por lo que se tratará como cuantitativa.
- Ast: número de asistencias de gol (min=0, máx=7)
- Pases_area: número de pases al área de penalti (min=1, máx=30).
- Centros_area: número de centros realizados al área de penalti (min=0, máx=11).
- Saques_banda: número de saques de banda realizados (min=6, máx=34).
- Corners: número de saques de esquina realizados (min=0, máx=16).
- Tarjeta_amarilla: número de tarjetas amarillas recibidas (min=0, máx=6).
- Faltas_cometidas: número de faltas cometidas por el Real Madrid (min=3, máx=22).
- Faltas_recibidas: número de faltas recibidas (min=4, máx=29).

## 3. ANÁLISIS PRELIMINAR

Antes de proceder con el ajuste de los modelos de regresión, se realizó un análisis exploratorio de los datos con el objetivo de comprobar la calidad de los datos. Además, se comprobó que no existen valores perdidos en ninguna de las variables.

### 3.1. Distribución de la variable dependiente:

La variable dependiente Goles_dico refleja si el Real Madrid marcó al menos dos goles en el partido (1) o menos de dos (0). En la muestra analizada, el 61,8% de los partidos terminaron con dos o más goles, mientras que el 38,2% de los partidos finalizaron con menos de dos goles. Esta distribución es adecuada, ya que se evita un desbalance extremo entre las categorías.

**Figura 1.** Distribución de la variable dependiente sin dicotomizar (izq) y dicotomizada (dcha).

**Estadísticos**

Goles

| | | |
|---|---|---|
| N | Válido | 228 |
| | Perdidos | 0 |
| Media | | 1,9693 |
| Mediana | | 2,0000 |
| Moda | | 2,00 |
| Desv. Desviación | | 1,44927 |
| Mínimo | | ,00 |
| Máximo | | 7,00 |

**Goles_dico**

| | | Frecuencia | Porcentaje | Porcentaje válido | Porcentaje acumulado |
|---|---|---|---|---|---|
| Válido | ,00 | 87 | 38,2 | 38,2 | 38,2 |
| | 1,00 | 141 | 61,8 | 61,8 | 100,0 |
| | Total | 228 | 100,0 | 100,0 | |

### 3.2. Estadísticos descriptivos de las variables independientes:

Se calcularon la media, desviación típica, mínimo y máximo de cada variable predictora. Se han comprobado posteriormente los supuestos de independencia y se ha evaluado la colinealidad para asegurar la validez del modelo.

**Figura 2.** Estadísticos descriptivos de las variables independientes

**Estadísticos descriptivos**

| | N | Mínimo | Máximo | Media | Desv. Desviación |
|---|---|---|---|---|---|
| Pos | 228 | 28,00 | 82,00 | 59,8596 | 8,37226 |
| Disparos | 228 | ,00 | 17,00 | 5,7368 | 2,80513 |
| Dist_disp | 228 | 12,00 | 26,10 | 18,0373 | 2,49309 |
| Penal_afavor | 228 | ,00 | 3,00 | ,2500 | ,55828 |
| Ast | 228 | ,00 | 7,00 | 1,4211 | 1,29652 |
| Pases_area | 228 | 1,00 | 30,00 | 11,1272 | 4,85803 |
| Centros_area | 228 | ,00 | 11,00 | 2,1579 | 1,87766 |
| Saques_banda | 228 | 6,00 | 34,00 | 18,9474 | 5,20224 |
| Corners | 228 | ,00 | 16,00 | 5,9649 | 2,96360 |
| Tarjeta_amarilla | 228 | ,00 | 6,00 | 1,9254 | 1,34677 |
| Tarjeta_roja | 228 | ,00 | 1,00 | ,0833 | ,27699 |
| Faltas_cometidas | 228 | 3,00 | 22,00 | 11,1272 | 3,56890 |
| Faltas_recibidas | 228 | 4,00 | 29,00 | 13,2193 | 4,20878 |
| N válido (por lista) | 228 | | | | |

### 3.3. Correlaciones con la variable dependiente y entre las predictoras

Se calcularon las correlaciones bivariadas entre cada variable predictora y la variable dependiente original *goles* (sin dicotomizar), así como entre las propias variables predictoras, con el objetivo de detectar posibles problemas de multicolinealidad y redundancia informativa.

El análisis reveló que algunas variables presentan correlaciones elevadas tanto con la variable dependiente como entre sí. En particular, la variable **Asistencias** (*Ast*) mostró una alta correlación con **Goles** (r = 0,863), ya que en la mayoría de las ocasiones los goles provienen directamente de una asistencia. Por tanto, ambas variables reflejan prácticamente la misma información ofensiva del equipo. Aunque en el modelo inicial se incluyen todas las variables predictoras disponibles, incluída Asistencias, se excluirá del modelo final para evitar esta redundancia.

La única otra variable predictora que presentó una correlación superior a ,40 con la variable dependiente original (*Goles*) fue **Disparos**, con una correlación moderada (r = ,500). Esta variable también se mantendrá en el modelo inicial, y se prevé que si resulta significativa se mantenga en el modelo final ya que su valor como predictor es conceptualmente relevante: representa la generación de oportunidades de gol, y no refleja exactamente el mismo concepto que el número de goles marcados.

En cuanto a las correlaciones entre las variables predictoras, en términos generales, se detectaron correlaciones moderadas entre algunas de ellas. Aunque estas correlaciones no implican necesariamente multicolinealidad severa, sí pueden dificultar la interpretación precisa de los coeficientes. Por tanto, se adoptará una interpretación cautelosa del modelo inicial, especialmente en lo relativo al $R^2$ y a la significación de predictores altamente correlacionados. Estas decisiones se irán ajustando en función del impacto de cada variable en los modelos y se basarán tanto en criterios estadísticos como conceptuales.

En concreto, se observó una elevada correlación entre algunos predictores, como **Centros al área** (*centros_area*) y **Corners**, lo que sugiere que ambas variables podrían estar midiendo una dimensión

común del juego ofensivo (acciones que generan oportunidades de gol cerca del área rival). Aunque se mantendrán ambas en un modelo inicial para evaluar empíricamente su relevancia conjunta, se anticipa la posible necesidad de excluir una de ellas en modelos posteriores para evitar problemas de redundancia.

Además, la variable **Pases_área** presenta correlaciones superiores a ,40 con varias variables, por lo que habrá que prestar atención a esta variable si finalmente resulta significativa y se incluye en el modelo final.

En la siguiente tabla se han incluido aquellas variables predictoras que correlacionan más entre sí, indicando en negrita las superiores a 0,40. La tabla completa de las correlaciones entre todos los predictores se encuentra en el anexo.

**Tabla 1.** Correlaciones entre predictores superiores a 0,40.

| | **Pases área** | **Posesión** | **Asistencia** | **Disparos** | **Centros** | **Corners** |
|---|---|---|---|---|---|---|
| **Pases área** | | | | | | |
| **Posesión** | **0,413** | | | | | |
| **Asistencia** | 0,173 | 0,009 | | | | |
| **Disparos** | **0,439** | 0,218 | **0,531** | | | |
| **Centros** | **0,609** | 0,170 | -0,024 | 0,187 | | |
| **Corners** | **0,471** | 0,340 | -0,057 | 0,316 | **0,413** | |

**Figura 3.** Diagnósticos de colinealidad

| Modelo | | Tolerancia | VIF |
|---|---|---|---|
| 1 | (Constante) | | |
| | Dist_disp | ,809 | 1,236 |
| | Penal_afavor | ,963 | 1,038 |
| | Ast | ,840 | 1,191 |
| | Pases_area | ,423 | 2,367 |
| | Centros_area | ,558 | 1,791 |
| | Saques_banda | ,883 | 1,133 |
| | Corners | ,689 | 1,452 |
| | Tarjeta_amarilla | ,768 | 1,301 |
| | Tarjeta_roja | ,879 | 1,138 |
| | Faltas_cometidas | ,819 | 1,221 |
| | Faltas_recibidas | ,835 | 1,198 |
| | Pos | ,630 | 1,588 |

Para completar el análisis de redundancia informativa, se realizó un análisis de multicolinealidad estimando los factores de inflación de la varianza (VIF) y los valores de tolerancia. Dado que SPSS requiere especificar una variable dependiente para ejecutar este procedimiento, se seleccionó de forma arbitraria una de las variables independientes como dependiente temporal. Esta decisión no afecta al objetivo del análisis, ya que tanto el VIF como la tolerancia evalúan exclusivamente la colinealidad entre las variables predictoras.

Los valores de VIF fueron inferiores a 5 y los valores de tolerancia superiores a 0,2 en todas las variables, lo que indica que no existen problemas graves de multicolinealidad (Hair et al., 2010). Estos resultados respaldan la inclusión simultánea de estas variables en el modelo de regresión logística binaria, aunque se interpretarán con precaución aquellos pares de predictores que presentan correlaciones elevadas.

## 4. ESPECIFICACIÓN DEL MODELO Y EVALUACIÓN

### 4.1. Modelo inicial completo

Dado que la variable dependiente utilizada en este estudio, goles dicotomizada (goles_dico), adopta únicamente dos posibles valores (más de dos goles vs. dos goles o menos), se optó por ajustar un modelo de regresión logística binaria. Este tipo de modelo permite interpretar los efectos de cada predictor en términos de probabilidades y razones (odds ratios), lo que resulta especialmente útil para aplicaciones prácticas en el contexto del rendimiento deportivo.

La decisión de dicotomizar la variable dependiente (número de goles) responde tanto a consideraciones prácticas como metodológicas. Por un lado, el número exacto de goles en un partido presenta una distribución de recuento con una marcada asimetría y una alta frecuencia de valores bajos (0, 1 o 2 goles), lo cual podría complicar el ajuste y la interpretación de modelos como la regresión lineal, que asume normalidad y homocedasticidad del error. Por otro lado, aunque un modelo de regresión de Poisson sería una alternativa natural para tratar con variables de conteo, la interpretación de los coeficientes puede resultar menos intuitiva para un público no técnico. Al transformar la variable en una forma dicotómica, se simplifica el análisis y se facilita la interpretación de los resultados en términos de probabilidades, lo que permite extraer conclusiones más claras sobre los factores que incrementan la probabilidad de un alto rendimiento ofensivo. De esta forma, se generó un modelo inicial utilizando la regresión logística binaria en el cual se incluyeron todas las variables independientes disponibles en la base de datos como predictores de la probabilidad de marcar más de dos goles en un partido.

Los resultados del ajuste global indican que el modelo completo mejora significativamente con respecto al modelo nulo, según la prueba de razón de verosimilitudes ($\chi^2(14) = 195{,}657$, $p < {,}001$), lo que sugiere que, en conjunto, los predictores incluidos ayudan a explicar la variable dependiente. Esta mejora también se refleja en el valor del logaritmo de la verosimilitud reducido (-2LL), que fue de 107,507 para el modelo ajustado. Asimismo, las medidas de pseudo-$R^2$ indican una elevada capacidad explicativa del modelo: el $R^2$ de Cox y Snell fue de ,576 y el $R^2$ de Nagelkerke alcanzó un valor de ,783. Este último, sugiere que el modelo explica aproximadamente el 78,3% de la varianza en la variable dependiente dicotómica. La capacidad predictiva del modelo también resulta adecuada: clasifica correctamente el 71,9% de los casos, con un 83,0% de acierto para los partidos en los que se marcaron más de dos goles, y un 54,0% de acierto para los partidos con dos goles o menos.

**Figura 4.** Contrastes y estadísticos de ajuste global.

**Resumen del modelo**

| Paso | Logaritmo de la verosimilitud -2 | R cuadrado de Cox y Snell | R cuadrado de Nagelkerke |
|---|---|---|---|
| 1 | 107,507[a] | ,576 | ,783 |

a. La estimación ha terminado en el número de iteración 7 porque las estimaciones de parámetro han cambiado en menos de ,001.

**Pruebas ómnibus de coeficientes de modelo**

| | | Chi-cuadrado | gl | Sig. |
|---|---|---|---|---|
| Paso 1 | Paso | 195,657 | 14 | ,000 |
| | Bloque | 195,657 | 14 | ,000 |
| | Modelo | 195,657 | 14 | ,000 |

**Figura 5.** Matriz de confusión

**Tabla de clasificación[a]**

| | | | Pronosticado | | |
|---|---|---|---|---|---|
| | | | Goles_dico | | |
| | Observado | | ,00 | 1,00 | Porcentaje correcto |
| Paso 1 | Goles_dico | ,00 | 75 | 12 | 86,2 |
| | | 1,00 | 12 | 129 | 91,5 |
| | Porcentaje global | | | | 89,5 |

a. El valor de corte es ,500

Aunque el modelo completo presenta un ajuste global aceptable, el análisis de los coeficientes (Figura 6) muestra que solo

cuatro variables resultan significativas al 5 %: *Disparos* (p = ,043), *Penaltis a favor* (p < ,001), *Asistencias* (p < ,001) y *Tarjetas rojas* (p = ,044). El resto de predictores no alcanzan significación estadística, lo que sugiere redundancia o escasa capacidad explicativa. Además, tal como se anticipó en el análisis de colinealidad, algunas variables conceptualmente similares —como *Asistencias y Goles*, o *Centros al área y Corners*— podrían estar generando solapamientos que afectan la estabilidad del modelo. Por ello, se plantea una depuración sistemática del modelo para seleccionar un subconjunto más parsimonioso y robusto de predictores, manteniendo tanto la validez estadística como la coherencia teórica. A continuación, se describe el procedimiento seguido para esta selección

**Figura 6.** Modelo inicial propuesto

**Variables en la ecuación**

| | | B | Error estándar | Wald | gl | Sig. | Exp(B) | 95% C.I. para EXP(B) Inferior | Superior |
|---|---|---|---|---|---|---|---|---|---|
| Paso 1[a] | Poss | -,066 | ,038 | 3,059 | 1 | ,080 | ,936 | ,869 | 1,008 |
| | Disparos | ,260 | ,129 | 4,077 | 1 | ,043 | 1,297 | 1,008 | 1,670 |
| | Dist_disp | -,214 | ,126 | 2,911 | 1 | ,088 | ,807 | ,631 | 1,032 |
| | Penal_afavor | 2,697 | ,702 | 14,760 | 1 | ,000 | 14,842 | 3,748 | 58,768 |
| | Pases_area | -,006 | ,081 | ,005 | 1 | ,941 | ,994 | ,849 | 1,164 |
| | Centros_area | -,207 | ,170 | 1,480 | 1 | ,224 | ,813 | ,583 | 1,135 |
| | Saques_banda | -,028 | ,052 | ,283 | 1 | ,595 | ,973 | ,879 | 1,077 |
| | Tarjeta_amarilla | ,061 | ,241 | ,064 | 1 | ,800 | 1,063 | ,663 | 1,704 |
| | Tarjeta_roja | -1,900 | ,944 | 4,050 | 1 | ,044 | ,150 | ,024 | ,952 |
| | Faltas_cometidas | ,012 | ,079 | ,024 | 1 | ,877 | 1,012 | ,868 | 1,181 |
| | Faltas_recibidas | ,050 | ,064 | ,618 | 1 | ,432 | 1,051 | ,928 | 1,191 |
| | Venue_num | -,797 | ,548 | 2,120 | 1 | ,145 | ,451 | ,154 | 1,318 |
| | Ast | 3,226 | ,531 | 36,959 | 1 | ,000 | 25,191 | 8,902 | 71,284 |
| | Corners | -,106 | ,101 | 1,092 | 1 | ,296 | ,899 | ,737 | 1,097 |
| | Constante | 5,308 | 3,623 | 2,146 | 1 | ,143 | 201,922 | | |

**4.2. Proceso de selección de variables:**

Como se indicó anteriormente, se procedió a un proceso de depuración del modelo con el objetivo de obtener una solución más parsimoniosa y estable. Se empleó un procedimiento de eliminación manual progresiva, comenzando por aquellas variables con alta redundancia teórica o correlaciones excesivas con otras variables o con la variable dependiente. En primer lugar, se eliminó la variable Asistencias, dado que su elevada correlación con la variable dependiente (goles) sugiere que ambas miden constructos prácticamente equivalentes, comprometiendo su independencia. Asimismo, se excluyó la variable Corners, altamente correlacionada con Centros al área. Dado que la mayoría de los córners se traducen en centros, se consideró que esta última recogía mejor la información relevante sin duplicarla.

Posteriormente, se eliminaron de forma secuencial aquellas variables cuya significación individual no alcanzaba el umbral convencional (p > ,05), comenzando por las menos significativas. Esta depuración se realizó de forma iterativa, evaluando en cada paso la mejora en la parsimonia del modelo y la estabilidad de los coeficientes.

Finalmente, el modelo reducido incluye solo las variables con una contribución estadísticamente significativa y teóricamente justificable: Posesión, Disparos, Distancia media de los disparos, Penaltis a favor, Centros al área, Tarjetas rojas y Lugar del partido, todas con valores de *p* inferiores a ,05. Sin embargo, el modelo no es definitivo, ya que se evaluarán posibles efectos de interacción entre las variables en los siguientes pasos.

**4.3. Evaluación de interacciones:**

Con el objetivo de explorar posibles efectos de interacción entre los predictores, se evaluaron todas las interacciones bivariadas posibles entre las variables del modelo previamente depurado. Este procedimiento se realizó de forma incremental, introduciendo cada interacción de manera individual en el modelo para valorar su significación estadística y su impacto sobre los efectos principales.

De todas las combinaciones evaluadas, únicamente resultó significativa la interacción entre la posesión y el número de disparos (p = ,023). La inclusión de este término modificó sustancialmente el patrón de resultados: la variable posesión, que anteriormente era significativa, dejó de serlo al considerar el efecto conjunto con los disparos (p = ,288). Esto sugiere un efecto de moderación, en el que la posesión solo tiene un impacto relevante sobre la probabilidad de marcar más de dos goles cuando se acompaña de un elevado número de disparos. Es decir, un alto porcentaje de posesión por sí solo no incrementa significativamente la probabilidad de lograr un alto rendimiento ofensivo, a menos que se traduzca en acciones de finalización efectivas.

**Figura 7.** Modelo reducido

**Variables en la ecuación**

| | | B | Error estándar | Wald | gl | Sig. | Exp(B) | 95% C.I. para EXP(B) Inferior | Superior |
|---|---|---|---|---|---|---|---|---|---|
| Paso 1[a] | Disparos | 1,287 | ,325 | 15,725 | 1 | ,000 | 3,622 | 1,917 | 6,844 |
| | Dist_disp | -,221 | ,079 | 7,745 | 1 | ,005 | ,802 | ,686 | ,937 |
| | Penal_afavor | 2,103 | ,493 | 18,170 | 1 | ,000 | 8,191 | 3,114 | 21,541 |
| | Centros_area | -,403 | ,103 | 15,194 | 1 | ,000 | ,668 | ,546 | ,818 |
| | Tarjeta_roja | -1,582 | ,617 | 6,574 | 1 | ,010 | ,206 | ,061 | ,689 |
| | Venue_num | -,839 | ,363 | 5,348 | 1 | ,021 | ,432 | ,212 | ,880 |
| | Disparos by Pos | -,014 | ,005 | 9,236 | 1 | ,002 | ,986 | ,978 | ,995 |
| | Constante | 3,953 | 1,801 | 4,821 | 1 | ,028 | 52,110 | | |

a. Variables especificadas en el paso 1: Disparos, Dist_disp, Penal_afavor, Centros_area, Tarjeta_roja, Venue_num, Disparos * Pos .

**5. RESULTADOS, EVALUACIÓN DE SUPUESTOS Y MODELO FINAL**

En este punto, el modelo que se considera potencialmente final incluye los 6 predictores que resultaron estadísticamente significativos tras el proceso de depuración, así como una interacción significativa entre disparos y posesión. No obstante, este modelo aún no se considera definitivo, ya que queda pendiente la evaluación de los supuestos fundamentales de la regresión logística binaria.

**5.1 Evaluación de los supuestos del modelo**

Uno de los supuestos clave en regresión logística binaria es la linealidad del logit, que exige que exista una relación lineal entre cada predictor cuantitativo y el logit (logaritmo del odds) de la variable dependiente. Para evaluar este supuesto, se categorizó cada predictor continuo y se aplicaron contrastes de tendencia polinómica. En el caso del predictor Centros al área, no se observó una relación lineal con el logit, ya que ninguno de los contrastes fue significativo (lineal: p = ,210; cuadrático: p = ,121; cúbico: p = ,545). Por tanto, se optó por recodificar esta variable como categórica en el modelo. Tras este cambio, se volvió a evaluar el modelo completo, y se comprobó que el resto de supuestos se cumplían adecuadamente. La linealidad sí se confirmó para el resto de predictores continuos: para Disparos, la tendencia lineal fue significativa (p < ,001), mientras que las componentes cuadrática y cúbica no lo fueron, lo que indica una relación aproximadamente lineal con el logit. En Distancia de disparo, se

observó una tendencia decreciente y sólo la tendencia lineal alcanzó significación (p = ,013). Penaltis a favor, también mostró una relación lineal significativa con el logit (p = ,002).

El supuesto de dispersión proporcional a la media se evaluó mediante el parámetro de escala, calculado como la razón entre la desviancia del modelo y sus grados de libertad. Utilizando una versión del modelo sin interacción (por restricciones del procedimiento multinomial), se obtuvo un valor de 0,99 (109,420 / 110), lo que indica una dispersión ajustada al modelo teórico. Esto sugiere que no hay indicios de sobredispersión ni infradispersión. Aunque la inclusión de la interacción en el modelo original reduciría ligeramente los grados de libertad, es razonable anticipar que el parámetro de escala seguiría cercano a 1, por lo que se considera que el supuesto se cumple adecuadamente.

Respecto al supuesto de independencia de las observaciones, se cumple adecuadamente dado el diseño del estudio (cada partido constituye una unidad de análisis independiente). Además, se examinaron los diagramas de dispersión entre los residuos estandarizados y cada una de las covariables continuas incluidas en el modelo. En todos los casos, los residuos se distribuyen de forma aleatoria en torno al valor cero, sin mostrar patrones sistemáticos ni relaciones discernibles, lo que sugiere que los errores son independientes respecto a las covariables.

Por último, se analizaron posibles valores atípicos e influyentes. Se detectó un único caso con un residuo estandarizado de -3,178 y un residuo studentizado de -2,21. Al no superar el umbral crítico (±3) en el residuo studentizado, no se considera que este caso tenga una influencia desproporcionada, por lo que no fue necesario excluirlo.

**5.2 Modelo definitivo**

Una vez evaluados los supuestos, se ajustó el modelo definitivo incluyendo los mismos predictores que inicialmente, con dos excepciones: se sustituyó la variable Centros al área en su versión continua por su versión categórica, y se excluyó el predictor Venue_num, ya que tras la modificación anterior, este dejó de ser significativo (p = ,060). Así, el modelo final incluye seis predictores y la constante: Disparos, Distancia de disparo (Dist_disp), Penaltis a favor (Penal_afavor), Centros al área (Centros_cat), Tarjetas rojas (Tarjeta_roja), la interacción Disparos × Posesión (Disparos by Pos).

El número de disparos tuvo un efecto positivo y significativo (B = 1,254, p < ,001), con una odds ratio (OR) de 3,504 [IC 95%: 1,882, 6,526], lo que indica que por cada disparo adicional, la probabilidad de marcar dos o más goles se multiplica por 3,5, manteniendo constantes el resto de variables del modelo. La variable Penal_afavor presentó el efecto positivo más fuerte (B = 1,901, OR = 6,695 [2,653, 16,900], p < ,001), lo que implica que tener un penalti a favor multiplica por 6,7 la probabilidad de marcar dos o más goles, siendo este uno de los predictores más fuertes del modelo.

En contraste, varias variables mostraron un efecto negativo significativo sobre la probabilidad de marcar dos o más goles. La distancia del disparo (B = -0,170, OR = 0,843 [0,729, 0,975], p = ,021) mostró que por cada metro adicional desde el que se realiza el disparo, la probabilidad de marcar dos o más goles se reduce en un 15,7%, lo que evidencia que disparar desde distancias más lejanas disminuye la efectividad ofensiva. En cuanto a las tarjetas rojas (B = -1,463, OR = 0,232 [0,073, 0,730], p = ,013), recibir una se asocia con una reducción del 76,8% en la probabilidad de marcar dos o más goles, reflejando el fuerte impacto negativo de jugar con un jugador menos.

Llama especialmente la atención el caso de la variable *Centros_area* (B = -0,367, OR = 0,693 [0,520, 0,924], p = ,013), que también se asoció con una menor probabilidad de marcar dos o más goles. En comparación con la categoría de referencia (el primer cuartil, el grupo con menos centros), pertenecer a una categoría superior en número de centros se asocia con una disminución del 30,7% en la

probabilidad del evento. Aunque este efecto puede parecer contraintuitivo, no se ha detectado colinealidad entre *Centros_area* y las demás variables del modelo. Este hallazgo podría reflejar que un elevado número de centros al área no implica necesariamente un juego ofensivo eficaz, sino que podría estar relacionado con un estilo de juego menos efectivo basado en balones al área como último recurso. Aunque se trata de un resultado inesperado, se ha mantenido en el modelo por su significación estadística y para permitir una interpretación más completa del conjunto de variables predictoras.

Finalmente, la interacción entre disparos y posesión (B = -0,014, OR = 0,987 [0,978, 0,995], p = ,002) también fue significativa, indicando que el efecto positivo de los disparos sobre la probabilidad marcar dos o más goles disminuye ligeramente a medida que aumenta la posesión. Es decir, los disparos tienen un mayor impacto en la probabilidad de marcar cuando el equipo tiene una menor posesión, pero siguen siendo importantes con alta posesión. Sin embargo, su valor predictivo disminuye ligeramente a medida que la posesión aumenta.

**Figura 8.** Modelo propuesto

**Variables en la ecuación**

| | | B | Error estándar | Wald | gl | Sig. | Exp(B) | 95% C.I. para EXP(B) Inferior | Superior |
|---|---|---|---|---|---|---|---|---|---|
| Paso 1[a] | Disparos | 1,254 | ,317 | 15,623 | 1 | ,000 | 3,504 | 1,882 | 6,526 |
| | Dist_disp | -,170 | ,074 | 5,307 | 1 | ,021 | ,843 | ,729 | ,975 |
| | Penal_afavor | 1,901 | ,472 | 16,200 | 1 | ,000 | 6,695 | 2,653 | 16,900 |
| | Centros_area (Agrupada) | -,367 | ,147 | 6,230 | 1 | ,013 | ,693 | ,520 | ,924 |
| | Tarjeta_roja | -1,463 | ,586 | 6,232 | 1 | ,013 | ,232 | ,073 | ,730 |
| | Disparos by Pos | -,014 | ,004 | 9,264 | 1 | ,002 | ,987 | ,978 | ,995 |
| | Constante | 1,819 | 1,543 | 1,389 | 1 | ,238 | 6,164 | | |

a. Variables especificadas en el paso 1: Disparos, Dist_disp, Penal_afavor, Centros_area (Agrupada), Tarjeta_roja, Disparos * Pos .

El ajuste global del modelo es bueno, según lo indica la prueba de razón de verosimilitudes ($\chi^2(6) = 72{,}741$, $p < ,001$), lo que muestra una mejora significativa respecto al modelo nulo. Además, los índices de $R^2$ indican una capacidad explicativa moderada: el coeficiente de Cox y Snell es de ,273, mientras que el de Nagelkerke alcanza ,371, lo que sugiere que el modelo explica aproximadamente el 37,1% de la varianza en la variable dependiente dicotómica. Aunque la capacidad explicativa del modelo es moderada, este modelo más parsimonioso y teóricamente coherente ofrece una interpretación más clara y robusta de los factores clave asociados a la probabilidad de marcar dos o más goles.

**Figura 9.** Ajuste global

**Pruebas ómnibus de coeficientes de modelo**

| | | Chi-cuadrado | gl | Sig. |
|---|---|---|---|---|
| Paso 1 | Paso | 72,741 | 6 | ,000 |
| | Bloque | 72,741 | 6 | ,000 |
| | Modelo | 72,741 | 6 | ,000 |

**Resumen del modelo**

| Paso | Logaritmo de la verosimilitud -2 | R cuadrado de Cox y Snell | R cuadrado de Nagelkerke |
|---|---|---|---|
| 1 | 230,422[a] | ,273 | ,371 |

a. La estimación ha terminado en el número de iteración 5 porque las estimaciones de parámetro han cambiado en menos de ,001.

**Prueba de Hosmer y Lemeshow**

| Paso | Chi-cuadrado | gl | Sig. |
|---|---|---|---|
| 1 | 8,433 | 8 | ,392 |

La ecuación del modelo de regresión logística resultante puede expresarse como:

$$\begin{aligned}\text{logit}(goles_dico = 1) = {} & 1.819 + 1.254 \cdot \text{Disparos} - 0.170 \cdot \text{Dist_disp} \\ & + 1.901 \cdot \text{Penal_afavor} - 0.367 \cdot \text{Centros_area} \\ & - 1.463 \cdot \text{Tarjeta_roja} - 0.014 \cdot (Pos \times Disparos)\end{aligned}$$

La tabla de clasificación muestra la capacidad del modelo final para predecir correctamente los valores observados de la variable dependiente dicotómica (Goles_dico). El modelo clasificó correctamente el 51,7% de los casos en los que el equipo marcó menos de dos goles (valor = 0) y el 80,9% de los casos en los que marcó dos o más goles (valor = 1). En conjunto, el modelo logró una tasa de clasificación global del 69,7%, lo que indica un rendimiento predictivo adecuado.

**Figura 10.** Tabla de clasificación

**Tabla de clasificación[a]**

| | | | Pronosticado | | |
|---|---|---|---|---|---|
| | | | Goles_dico | | |
| | Observado | | Meter menos de dos goles | Meter dos o más goles | Porcentaje correcto |
| Paso 1 | Goles_dico | Meter menos de dos goles | 45 | 42 | 51,7 |
| | | Meter dos o más goles | 27 | 114 | 80,9 |
| | Porcentaje global | | | | 69,7 |

a. El valor de corte es ,500

## 6. DISCUSIÓN Y CONCLUSIONES

Este estudio ha identificado un conjunto de variables clave que contribuyen a predecir la probabilidad de que el Real Madrid marque dos o más goles en un partido de La Liga, utilizando un

modelo de regresión logística binaria. Partiendo de un modelo inicial con múltiples indicadores del rendimiento en los partidos, se realizó un proceso de depuración y evaluación de interacciones, lo que resultó en un modelo más parsimonioso y respaldado teóricamente.

Las variables que resultaron estadísticamente significativas en el modelo final incluyen el número de disparos, la distancia media de los disparos, los penaltis a favor, los centros al área, las tarjetas rojas y el lugar del partido (local vs. visitante). Además, se detectó una interacción significativa entre la posesión del balón y el número de disparos, lo que sugiere que la posesión solo aumenta la probabilidad de marcar dos o más goles cuando se traduce en oportunidades de finalización efectivas.

Debe tenerse en cuenta que el modelo explica una parte importante, aunque no total, de la varianza de la variable dependiente (Nagelkerke $R^2 = .371$), por lo que existen otros factores no incluidos en el análisis que también influyen en el rendimiento ofensivo.

En resumen, el modelo final desarrollado presenta un buen ajuste global, una capacidad predictiva aceptable y una base teórica sólida que respalda la inclusión de los predictores seleccionados.

## 8. REFERENCIAS

Constantinou, A. C., Fenton, N. E., & Neil, M. (2012). Pi-football: A Bayesian network model for forecasting Association Football match outcomes. *Knowledge-Based Systems, 36*, 322–339. https://doi.org/10.1016/j.knosys.2012.07.008

Hair, J. F., Black, W. C., Babin, B. J., & Anderson, R. E. (2010). *Multivariate data analysis* (7th ed.). Pearson.

Hvattum, L. M., & Arntzen, H. (2010). Using ELO ratings for match result prediction in association football. *International Journal of Forecasting, 26*(3), 460–470. https://doi.org/10.1016/j.ijforecast.2009.10.002

# 9. ANEXO

| | | Pos | Disparos | Dist_disp | Penal_afavor | Ast | Pases_area | Centros_area | Saques_banda | Corners | Tarjeta_amarilla | Tarjeta_roja | Faltas_cometidas | Faltas_recibidas |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Pos | Correlación de Pearson | 1 | ,218** | ,088 | -,009 | ,009 | ,413** | ,170* | ,194** | ,340** | -,156* | -,128 | -,292** | ,174** |
| | Sig. (bilateral) | | ,001 | ,186 | ,887 | ,896 | ,000 | ,010 | ,003 | ,000 | ,018 | ,054 | ,000 | ,008 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Disparos | Correlación de Pearson | ,218** | 1 | -,260** | -,084 | ,531** | ,439** | ,187** | -,020 | ,316** | -,146* | ,000 | -,092 | -,147* |
| | Sig. (bilateral) | ,001 | | ,000 | ,204 | ,000 | ,000 | ,005 | ,761 | ,000 | ,027 | 1,000 | ,166 | ,026 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Dist_disp | Correlación de Pearson | ,088 | -,260** | 1 | ,116 | -,258** | -,202** | -,199** | -,118 | -,035 | ,116 | -,073 | -,071 | ,105 |
| | Sig. (bilateral) | ,186 | ,000 | | ,081 | ,000 | ,002 | ,003 | ,074 | ,603 | ,082 | ,270 | ,284 | ,113 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Penal_afavor | Correlación de Pearson | -,009 | -,084 | ,116 | 1 | -,018 | ,003 | ,025 | -,099 | -,064 | -,022 | -,050 | ,026 | ,052 |
| | Sig. (bilateral) | ,887 | ,204 | ,081 | | ,784 | ,966 | ,705 | ,138 | ,337 | ,741 | ,454 | ,696 | ,438 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Ast | Correlación de Pearson | ,009 | ,531** | -,258** | -,018 | 1 | ,173** | -,024 | -,063 | -,057 | -,148* | -,086 | ,008 | -,174** |
| | Sig. (bilateral) | ,896 | ,000 | ,000 | ,784 | | ,009 | ,721 | ,341 | ,392 | ,025 | ,196 | ,900 | ,008 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Pases_area | Correlación de Pearson | ,413** | ,439** | -,202** | ,003 | ,173** | 1 | ,609** | ,028 | ,471** | -,250** | -,064 | -,163* | -,207** |
| | Sig. (bilateral) | ,000 | ,000 | ,002 | ,966 | ,009 | | ,000 | ,670 | ,000 | ,000 | ,339 | ,014 | ,002 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Centros_area | Correlación de Pearson | ,170* | ,187** | -,199** | ,025 | -,024 | ,609** | 1 | ,119 | ,413** | -,173** | -,042 | -,057 | -,143* |
| | Sig. (bilateral) | ,010 | ,005 | ,003 | ,705 | ,721 | ,000 | | ,072 | ,000 | ,009 | ,525 | ,392 | ,031 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Saques_banda | Correlación de Pearson | ,194** | -,020 | -,118 | -,099 | -,063 | ,028 | ,119 | 1 | ,131* | -,045 | -,049 | -,076 | -,053 |
| | Sig. (bilateral) | ,003 | ,761 | ,074 | ,138 | ,341 | ,670 | ,072 | | ,048 | ,503 | ,462 | ,256 | ,426 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Corners | Correlación de Pearson | ,340** | ,316** | -,035 | -,064 | -,057 | ,471** | ,413** | ,131* | 1 | -,097 | ,052 | -,170* | -,033 |
| | Sig. (bilateral) | ,000 | ,000 | ,603 | ,337 | ,392 | ,000 | ,000 | ,048 | | ,146 | ,436 | ,010 | ,625 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Tarjeta_amarilla | Correlación de Pearson | -,156* | -,146* | ,116 | -,022 | -,148* | -,250** | -,173** | -,045 | -,097 | 1 | ,288** | ,321** | ,133* |
| | Sig. (bilateral) | ,018 | ,027 | ,082 | ,741 | ,025 | ,000 | ,009 | ,503 | ,146 | | ,000 | ,000 | ,044 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Tarjeta_roja | Correlación de Pearson | -,128 | ,000 | -,073 | -,050 | -,086 | -,064 | -,042 | -,049 | ,052 | ,288** | 1 | ,123 | ,022 |
| | Sig. (bilateral) | ,054 | 1,000 | ,270 | ,454 | ,196 | ,339 | ,525 | ,462 | ,436 | ,000 | | ,064 | ,741 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Faltas_cometidas | Correlación de Pearson | -,292** | -,092 | -,071 | ,026 | ,008 | -,163* | -,057 | -,076 | -,170* | ,321** | ,123 | 1 | -,047 |
| | Sig. (bilateral) | ,000 | ,166 | ,284 | ,696 | ,900 | ,014 | ,392 | ,256 | ,010 | ,000 | ,064 | | ,480 |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |
| Faltas_recibidas | Correlación de Pearson | ,174** | -,147* | ,105 | ,052 | -,174** | -,207** | -,143* | -,053 | -,033 | ,133* | ,022 | -,047 | 1 |
| | Sig. (bilateral) | ,008 | ,026 | ,113 | ,438 | ,008 | ,002 | ,031 | ,426 | ,625 | ,044 | ,741 | ,480 | |
| | N | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 | 228 |

**. La correlación es significativa en el nivel 0,01 (bilateral).

*. La correlación es significativa en el nivel 0,05 (bilateral).